



UNIVERSITÀ DEGLI STUDI DELL'AQUILA

DIPARTIMENTO DI INGEGNERIA E SCIENZE
DELL'INFORMAZIONE E MATEMATICA



CORSO DI LAUREA IN INFORMATICA

Stima efficiente del numero di Network Motifs tramite Color-Coding e decomposizioni bilanciate

Relatore:

Dott. Stefano Leucci

Candidato:

Giulia Scoccia

Correlatore:

Prof. Guido Proietti

Matricola:

249503

ANNO ACCADEMICO 2019–2020

1	Introduzione	2
1.1	Contributo della tesi	3
1.2	Organizzazione del testo	4
2	Color Coding	5
2.1	Algoritmo	5
2.2	Dettagli implementativi. Rappresentazione compatta dei treelet colorati e rispettivi conteggi	9
3	Algoritmo ottimizzato tramite decomposizioni bilanciate	13
3.1	Decomposizioni bilanciate di un albero	13
3.2	Algoritmo	19
3.3	Dettagli implementativi. Modifica e aggiunte alle rappresentazioni . .	23
4	Analisi Sperimentale	25
5	Conclusioni	26

I Motif, anche chiamati Graphlet o Pattern, sono piccoli sottografi connessi indotti di un grafo ed il loro conteggio è un problema ben noto del graph mining e dell'analisi dei social network. Più precisamente, dato in input un grafo G e un intero positivo k , il problema richiede di contare, per ogni graphlet H di k nodi, il numero di sottografi indotti di G isomorfi ad H . Comprendere la distribuzione dei motif in un grafo fa luce sul tipo di strutture locali presenti in esso che possono essere usate per molteplici tipi di analisi applicate, per esempio, a reti sociali [1, 2, 3], biologiche [4], Poichè il conteggio esatto del numero di occorrenze dei graphlet risulta computazionalmente impegnativo, di solito ci si accontenta di obiettivi meno ambiziosi come la stima *approssimata* della loro frequenza: per ogni sottografo di k nodi si richiede di stimare, nel modo più accurato possibile, la sua frequenza relativa rispetto a tutti i sottografi della stessa dimensione (i.e., numero di nodi). Dal momento che il numero di motif cresce più che esponenzialmente rispetto al numero di nodi k , spesso si restringe l'attenzione al problema della stima della frequenza relativa dei soli sottografi che compaiono il maggior numero di volte nel grafo input. Ci sono due approcci principali per ottenere tali stime: Il primo utilizza i metodi di Monte Carlo basati sulle catene di Markov (MCMC), mentre il secondo sfrutta la tecnica del Color Coding introdotta da Alon, Yuster e Zwick [5]. Studi recenti analizzano le differenze tra i due approcci concludendo che, seppure l'elevata complessità spaziale delle tecniche basate sul color coding può limitarne l'utilizzo, tali

tecniche forniscono garanzie di accuratezza migliori rispetto agli approcci MCMC. Per tale motivo, nel resto di questa tesi ci concentreremo solo sulla tecnica del Color Coding. Tale tecnica è stata introdotta per risolvere in maniera randomizzata il problema di determinare l'esistenza di sottografi isomorfi a cammini ed alberi con treewidth limitata nel grafo G in input. Un'estensione di questa tecnica consente inoltre di ottenere garanzie statistiche forti per il problema del Motif Counting da cui le frequenze possono essere facilmente derivate. Tale estensione si basa su due osservazioni chiave. La prima è che il Color Coding può essere usato per costruire “un'urna” astratta che contiene un sottoinsieme statisticamente rappresentativo di tutti i sottografi di G (non necessariamente indotti) che hanno esattamente k nodi e sono alberi. La seconda osservazione è che il compito di campionare k -graphlet, ossia graphlet con k nodi, può essere ridotto a quello di campionare k -alberi, ossia alberi con k nodi, dall'urna. Si può così stimare il numero dei motif in due fasi: la “fase di costruzione” in cui si crea l'urna da G e la “fase di campionamento” dove si “estraggono” degli alberi dall'urna fino ad ottenere delle stime accurate per i graphlet di interesse.

1.1 Contributo della tesi

In questo lavoro di tesi l'attenzione si è concentrata principalmente sull'ottimizzazione di un algoritmo basato sulle tecnica del Color Coding per il conteggio delle occorrenze di tutti i k -treelet presenti nel grafo G in input, dove per k -treelet si intendono alberi con k nodi e ed un occorrenza di un k -treelet T in G è un sottografo (non necessariamente indotto) isomorfo a T . Ciò corrisponde alla “fase di costruzione” descritta in precedenza. Tale fase può essere descritta mediante un algoritmo basato sulla tecnica della programmazione dinamica. In primo luogo, tramite il lavoro svolto, si è implementato l'algoritmo descritto in [6] in Java. L'algoritmo, supposto di voler conteggiare i treelet di dimensione k di un grafo, lavora in esattamente k fasi. Nell' i -esima fase (con $i \in \{1, \dots, k\}$), vengono conteggiati i treelet di dimensione i . Tali conteggi saranno ottenuti in funzione della struttura del grafo e del numero di occorrenze dei treelet con un numero di nodi compreso tra 1 ed $i - 1$. Ne segue che per poter calcolare il numero di occorrenze dei treelet di dimensione k ,

sarà necessario aver già calcolato quelli di dimensione fino a $k - 1$. Tale dipendenza è evidenziata dalle formule di ricorrenza che descrivono l'algoritmo di programmazione dinamica, che verrà descritto nella sezione 2.1. Poichè il numero dei k -treelet cresce in maniera esponenziale rispetto a k , l'algoritmo può essere eseguito solo per valori piccoli di k prima che il tempo richiesto diventi eccessivo.

A tal proposito nella tesi viene proposta un'ottimizzazione, basata su opportune decomposizioni “bilanciate” degli alberi, che consente di rendere indipendenti i conteggi dei treelet di dimensione k da circa un terzo dei conteggi precedenti. Tale ottimizzazione permette di eseguire solo le prime $\frac{2}{3}k + O(1)$ (si veda la sezione 3.3 per maggiori dettagli) fasi prima della fase k , comportando un risparmio notevole di tempo.

Inoltre sono stati fatte analisi sperimentali su cinque grafi, con lo scopo di mostrare oltre all'accuratezza dei risultati, anche il risparmio di tempo che si ottiene nell'utilizzo della tecnica ottimizzata rispetto a quella non ottimizzata. Ad esempio, su un grafo sociale con 63731 nodi e 817090 archi, l'algoritmo non ottimizzato richiede DA VEDERE tempo per la ricerca dei treelet con DA VEDERE nodi, mentre quello ottimizzato richiede un tempo DA VEDERE.

1.2 Organizzazione del testo

La tesi è strutturata nel seguente modo. Nel capitolo 2 verrà descritta la tecnica del color coding e il suo utilizzo per il conteggio degli alberi. Si vedrà l'algoritmo di [6], la sua formulazione e le scelte adottate in fase implementativa. Nel capitolo 3 si discuterà in dettaglio la tecnica delle decomposizioni bilanciate ed il relativo impatto sull'algoritmo. Anche in questo caso si discuteranno le scelte effettuate in fase implementativa. Nel capitolo 4 verranno mostrati i risultati dell'analisi sperimentale delle performance dell'algoritmo ottimizzato confrontandolo con l'implementazione della versione di [6]. Infine, nel capitolo 5, verranno discusse le possibili estensioni del presente lavoro di tesi al problema più generale della stima del numero di occorrenze dei graphlet.

CAPITOLO 2

COLOR CODING

In questo capitolo verrà descritta la tecnica del Color Coding utilizzata in questa tesi.

La tecnica fu introdotta nel 1995 da Alon, Yuster e Zwick [5]. In generale, dati due grafi G ed H , il problema di individuare un sottografo indotto di G isomorfo ad H è un problema NP -completo, ma può essere risolto in tempo polinomiale tramite un algoritmo randomizzato per classi particolari di grafi H , usando la tecnica del color coding.

Il primo algoritmo che Alon e i suoi colleghi descrissero in [5], però, risolve tale problema quando H è un cammino o un albero con treewidth costante limitandosi, inoltre, alla sola ricerca senza farne un conteggio del numero delle occorrenze totali.

In questo capitolo, si presenta un'estensione dell'algoritmo descritto da Alon [5, 6] che per effettuare un conteggio delle occorrenze di tutti i treelet all'interno del grafo.

2.1 Algoritmo

Dati in input un grafo $G = (V, E)$ ed un intero positivo k , per prima cosa il color coding assegna indipendentemente ed uniformemente a caso un colore $c_v \in [k] = \{1, \dots, k\}$ ad ogni nodo $v \in V$ di G . Dato un sottografo H di G , diremo che H è *ben colorato* se ogni nodo v di H ha un colore c_v distinto.

Il cuore dell'algoritmo consiste nel conteggiare il numero di occorrenze (non necessariamente indotte) di alberi ben-colorati di k -nodi in G . Questo viene fatto in maniera efficiente mediante programmazione dinamica, una tecnica che risolve dei sottoproblemi del problema di interesse, procedendo dai problemi “più piccoli” verso quelli “più grandi” e ricostruendo le relative soluzioni in funzione delle soluzioni già calcolate per i problemi precedentemente risolti, fino a risolvere il problema originario.

Nel seguito denoteremo con T_C un *treelet colorato*, ovvero una coppia (T, C) dove T un albero radicato e $C \subseteq \{1, \dots, k\}$. Per ogni nodo $v \in V$ e per ogni treelet colorato T_C , con k nodi, si vuole calcolare il numero $c(T_C, v)$ di occorrenze (non indotte) di T_C in G che sono radicate in v .

Inizialmente per ogni nodo v si inizializza $c(T_C, v) = 1$, dove T è il treelet di 1 nodo e $C = \{c_v\}$. Dopodichè, per ogni $h = 2, \dots, k$, si considera ogni possibile albero radicato T di dimensione h , ogni possibile insieme di colori $C \subseteq [k]$ con $|C| = h$ ed ogni nodo $v \in V$. L'albero T_C viene *decomposto* in due alberi T' e T'' come segue: T'' è il sottoalbero radicato in uno dei figli della radice v di T e T' è il sottoalbero di T radicato in v tale che $T' = T \setminus T''$. In questa tesi la scelta di T' e T'' non è casuale, ma bensì vengono scelti garantendo un'ordinamento non crescente sugli alberi radicati nei figli della radice v di T . Questo implica, perciò, che non sarà mai possibile che l'albero T'' abbia una grandezza superiore di T' . Più precisamente, non potrà mai risultare che la grandezza di T'' superi la grandezza dell'albero radicato nell'ultimo figlio della radice v di T' .

Ne segue che, per un'opportuna partizione dei colori C in due insiemi C' e C'' , ogni occorrenza di T_C in G implica l'esistenza due occorrenze distinte $T'_{C'} = (T', C')$ e $T''_{C''} = (T'', C'')$ in G radicate, rispettivamente nei nodi v e u . Viceversa, ogni coppia di occorrenze $T'_{C'}$ e $T''_{C''}$ radicate, rispettivamente, in v e u induce un'occorrenza (non necessariamente distinta) di T_C radicata in v . In particolare è facile osservare che chiamato β_T il numero di sottoalberi di T radicati in un figlio di r isomorfi a T'' , esistono esattamente β_T coppie di occorrenze $T'_{C'}$ e $T''_{C''}$ che inducono T_C .

Dalla discussione seguente segue che, per calcolare $c(T_C, v)$ è sufficiente conside-

rare tutti treelet colorati radicati in v isomorfi a $T'_{C'}$ e tutti i treelet radicati in un vicino u di v isomorfi a $T''_{C''}$, tali che $C', C'' \subseteq [k]$ con $C' \cup C'' = C$ e $C' \cap C'' = \emptyset$. Sia per T' che per T'' è noto il numero di occorrenze $c(T'_{C'}, v)$ e $c(T''_{C''}, u)$ in G , poichè $|T'|, |T''| \leq h - 1$. Pertanto:

$$c(T_C, v) = \frac{1}{\beta_T} \sum_{(u,v) \in E} \sum_{\substack{C', C'' \subseteq C: |C'|=|T'| \\ C' \cup C'' = C \\ C' \cap C'' = \emptyset}} c(T'_{C'}, v) \cdot c(T''_{C''}, u). \quad (1)$$

La correttezza e la complessità di questo algoritmo, non sono trattate in questa tesi, ma vengono dimostrate da Alon in [5].

Si può vedere l'algoritmo formalmente descritto in Algoritmo 1.

Algoritmo 1: Algoritmo di costruzione per i k -treelet in T

```

1 input : Grafo  $G = (V, E)$ , dimensione del treelet  $k$ , insieme  $[k]$  di colori;
2 for  $v \in V$  do
3   Sia  $c_v$  un colore scelto uniformemente a caso in  $[k]$ ;
4   Sia  $T$  il treelet contenente un solo nodo;
5    $T_C = (T, \{c_v\})$ ;
6    $c(T_C, v) = 1$ ;
7 end
8 for  $h = 2$  to  $k$  do
9   for  $v \in V$  do
10    foreach  $T : |T| = h$  do
11      «««< HEAD Suddivido  $T$  in due alberi  $T'$  e  $T''$  come descritto in
        precedenza nella sezione 2.1
        
$$c(T_C, v) = \frac{1}{\beta_T} \sum_{(u,v) \in E} \sum_{\substack{C', C'' \subseteq C \\ C' \cup C'' = C \\ C' \cap C'' = \emptyset}} c(T'_{C'}, v) \cdot c(T''_{C''}, u)$$

12    end
13  end
14 end

```

Come si può notare, per calcolare le occorrenze di un albero T_C nell'algoritmo si

sfrutta un approccio basato sulle “scomposizioni”, ossia, a partire dall’albero T_C , si identificano i due alberi T' e T'' in cui può essere scomposto, si considerano tutte le partizioni di $C', C'' \subset C$ e in seguito si procede al calcolo di $c(T_C, v)$ come indicato in (1).

In questa tesi, così come in [7], si è sfruttato un approccio basato sulle “unioni”. Infatti, per ogni nodo $v \in V$ di G e per ogni nodo $u \in V$ con $(u, v) \in E$ si prendono tutte le coppie possibili di treelet colorati radicati in v e u , rispettivamente $T'_{C'}$ e $T''_{C''}$, e si verifica se esiste un albero T_C radicato in v per cui la coppia T' e T'' rappresenta una decomposizione ammissibile e tale che C' e C'' sono una partizione di C . Sarà pertanto necessario che dati due alberi T' e T'' siano tali che il numero totale di nodi che contengono, che indicheremo rispettivamente con $|T'|$ e $|T''|$, sia: $|T'|, |T''| > 0$ e che $|T'| + |T''| = k$.

Anche in questo caso si vuole ottenere solo i k -treelet T in cui i sottoalberi radicati nella radice r abbiano un ordinamento non crescente. Perciò se la struttura di T'' è più grande della struttura del sottoalbero radicato nell’ultimo figlio della radice di T' , non è possibile compiere l’unione tra i due.

Si noti che i conteggi del numero di occorrenze di ogni k -treelet colorato radicato in ogni nodo $v \in V$ di G , sono calcolati e salvati in maniera indipendente. Lo scopo di questa tesi però è quello di stimare, per ogni k -treelet T^* , il numero $N(T^*)$ di sottografi (non necessariamente indotti) isomorfi a T^* nel grafo G . A tal proposito si noti che ogni occorrenza O di un generico k -treelet T in G è responsabile dell’incremento di 1 di esattamente k contatori $c(T_C, v)$. In particolare tali contatori si riferiscono ai nodi v di O e agli alberi $T_C = (T, C)$ per cui $C = \{1, \dots, k\}$ e T è ottenuto radicando T nel nodo corrispondente a v .

Sia \mathcal{T} l’insieme di tutti gli alberi isomorfi a T e $\tilde{N}(T)$ il numero di occorrenze ben colorate di T in G . Dalla discussione precedente segue che: $\tilde{N}(T) = \frac{1}{k} \sum_{T \in \mathcal{T}} \sum_{v \in V} c(T_C, v)$ dove $T_C = (T, \{1, \dots, k\})$. Inoltre, poichè ogni occorrenza di un k -treelet T in G è ben colorata con probabilità $\frac{k!}{k^k}$, uno stimatore unbiased del numero di $N(T^*)$ è $\frac{k^k}{k!} \cdot \tilde{N}(T)$, cioè $\mathbb{E} \left[\frac{k^k}{k!} \cdot \tilde{N}(T) \right] = N(T^*)$.

Quello che è stato fatto in questa tesi per arrivare a calcolare il valore di $N(T^*)$ sono due passaggi fondamentali.

Al fine di calcolare $\tilde{N}(T)$ per ogni k -treelet T ben colorato in G , quello che si fa è calcolare i conteggi $c(T_C, v)$ solo per quei treelet la cui radice v sia tale per cui $c_v = 0$. Si noti che la scelta del colore è arbitraria e ristretta ad un colore tra 0 e k . Così facendo ogni occorrenza O , sarà responsabile di un unico incremento piuttosto che di k . In questo modo non sarà necessario calcolare $\tilde{N}(T)$ perchè il numero di occorrenze degli alberi sarà già ben calcolato.

Il secondo passaggio fondamentale invece sarà quello di aggregare gli alberi in opportuni insiemi. Tale suddivisione viene effettuata sulla base di opportune classi di equivalenza basate su isomorfismi.

Pertanto se due alberi T e T' sono isomorfi apparterranno allo stesso insieme, $T = (V, E)$ e $T' = (V', E')$ si dicono isomorfi se esiste una funzione bigettiva $f : V \rightarrow V'$ tale che $(u, v) \in E$ se e solo se $(f(u), f(v)) \in E'$.

Per ogni insieme viene scelto un opportuno rappresentante sul quale saranno aggregati tutti i conteggi degli alberi a lui isomorfi. Solo una volta divisi gli alberi negli opportuni insiemi sarà possibile eseguire direttamente il calcolo di $N(T)$ per ogni T rappresentante delle classi di equivalenza.

2.2 Dettagli implementativi. Rappresentazione compatta dei treelet colorati e rispettivi conteggi

In questa sezione vengono descritte le strutture dati usate per implementare l'algoritmo in Java. Gli oggetti principali che vengono manipolati sono i treelet colorati e le occorrenze associate.

Ogni treelet colorato $T_C = (T, C)$ ha una rappresentazione unica nella quale sono memorizzate la topologia di T , i colori in C ed informazioni aggiuntive per facilitare la manipolazione di T_C . Tale rappresentazione richiede al più 58 bit e può pertanto essere memorizzata usando degli interi a 64 bit, un tipo di dati nativo in Java, nelle più comuni architetture moderne. I bit sono numerati da 0 a 63 e ordinati dal bit meno significativo a quello più significativo.

Sono così suddivisi:

- i bit da 0-3 contengono il numero di nodi di T a meno della radice.

- i bit da 4-7 contengono la dimensione del sottoalbero radicato nell'ultimo figlio della radice di T .
- i bit da 8-11 vengono usati per memorizzare il valore di β_T associato a T .
- i bit da 12-27 sono usati per indicare i colori in C .
- i bit da 28-58 sono usati per codificare la struttura del treelet, come descritto di seguito.
- gli ultimi 5 bit sono lasciati a zero.

Per codificare la struttura dell'albero si procede a partire da una visita in profondità (DFS) su T .

In questo caso la visita avviene partendo dalla radice r di T e attraversando tutti gli archi. Al termine ogni arco sarà stato attraversato esattamente 2 volte, in direzioni opposte.

Sia $h = |T|$ e sia e_i , con $i = 1, 2, \dots, 2(h-1)$, l' i -esimo arco attraversato dalla visita. L' i -esimo bit della codifica è 0 se e_i è attraversato in direzione di r in T e 1 in caso contrario.

In Figura 2.1 si può vedere un esempio di tale codifica.




Figura 2.1: Un treelet radicato e la codifica della sua struttura

Per un qualunque $k \leq 16$ questa codifica richiede al massimo 30 bit. L'ordinamento lessicografico sulla struttura definisce anche implicitamente un'ordinamento totale sui treelet. Questo ordinamento è anche una regola decisiva per la visita DFS: i figli di un nodo vengono visitati nell'ordine indotto dai sottoalberi radicati in essi. Ciò implica che ogni treelet T ha una codifica unica ed ogni codifica valida corrisponde ad un solo treelet. Inoltre, in questo modo è possibile implementare

rapidamente l'operazione di unione.

La codifica dei treelet supporta le seguenti operazioni :

- **singleton** (c) : permette di inizializzare un treelet di un solo nodo con il rispettivo colore $c \in \{1, \dots, k\}$
- **merge** (T'_C, T''_C) : fa l'unione di due alberi T' e T'' e se possibile crea un nuovo albero T che avrà come struttura la concatenazione delle strutture di T' e T'' (a meno della radice). La dimensione, a meno della radice, sarà data dalla somma delle dimensioni di T' e T'' più 1. I colori di T , sono il risultato dell'unione dei colori di T' e T'' . β_T sarà, inizialmente, pari al valore $\beta_{T'}$ corrispondente a T' e se la struttura del sottoalbero radicato nell'ultimo figlio di T' è uguale alla struttura di T'' viene eventualmente incrementato di 1. Per finire, la dimensione del sottoalbero più piccolo radicato in T sarà esattamente la dimensione di T'' , a meno della radice, più 1 .
- **normalization_factor** (T_C): restituisce la costante di normalizzazione β_T associata a T_C .




Figura 2.2: un treelet colorato $T_C = (T, C)$ e la sua codifica, mostrata per semplicità solo su $8+8+4+4+4=28$ bit

In Figura 2.2 è mostrato un esempio di treelet colorato e della sua codifica

Nell'implementazione i treelet individuati da ogni nodo e i rispettivi conteggi vengono salvati all'interno di una tabella indicizzata, rappresentata mediante strutture annidate di *ArrayList*.

Inizialmente, come nell'algoritmo 1, i treelet e i conteggi sono stati valutati su ogni nodo $v \in V$ di G scorrendo tutti gli archi E , quello che si ha, però è una tabella

con k entrate indicizzate da 1 a k ed associate al numero di vertici dei treelet.

L' i -esima entrata della tabella, con $1 \leq i \leq k$ generico, a sua volta, è un *ArrayList*, con una dimensione fissata, che varia a secondo della cardinalità di V , così che ad ogni entrata è associato un vertice $v \in V$ di G .

Per ognuna delle $|V|$ entrate, viene creato un *ArrayList* contenente tutti i treelet colorati di dimensione i raggiungibili dai differenti nodi in V , insieme al relativo numero di occorrenze.

All'interno di quest'ultima lista i treelet sono ordinati in ordine non decrescente.

Per permettere una costruzione più rapida della tabella, nell'implementazione è utilizzato il *Multithreading*, cioè vengono utilizzati più thread che lavorano in parallelo. Un thread è un flusso di esecuzione indipendente all'interno di un processo. Il numero di thread utilizzato nell'implementazione è dipendente dal numero di processori presenti nella macchina.

CAPITOLO 3

ALGORITMO OTTIMIZZATO TRAMITE DECOMPOSIZIONI BILANCIATE

In questo capitolo viene presentata un'ottimizzazione all'algoritmo descritto nel capitolo 2. basata sull'idea di decomporre gli alberi T in una coppia di alberi T' e T'' con un numero simile di nodi. Si fa vedere, inoltre, come modificare i dettagli implementativi precedentemente discussi.

3.1 Decomposizioni bilanciate di un albero

Nel precedente capitolo, dato un albero T con $|T| = k$, viene considerata la decomposizione di T in due alberi T' e T'' . Dipendentemente da T , tale decomposizione può restituire un albero T' (o T'') contenente un numero esiguo di nodi rispetto a $|T|$. Un esempio dove questo fenomeno è particolarmente evidente si verifica quando T è una stella di k nodi per cui $|T'| = k - 1$ e $|T''| = 1$.

In questa sezione si mostrerà che dato un albero T è sempre possibile ricavare una decomposizione “bilanciata” dell'albero in due alberi T' e T'' le cui cardinalità distino al al più di una costante moltiplicativa.

Prima di poter enunciare e dimostrare il risultato principale occorre dare delle nozioni preliminari.

Definizione 3.1.1. Sia T_r un albero, con k nodi, radicato nel nodo r . Diremo che la coppia (A, B) , dove A e B sono due sottoalberi di T_r , è una decomposizione per l'albero T_r se:

- $|A| + |B| = k$; e
- A e B condividono solo il nodo r .

Definizione 3.1.2. Data una funzione $f : \mathbb{N} \rightarrow \mathbb{N}$ ed un albero T con k , diremo che (A, B) è una decomposizione $f(k)$ -bilanciata se:

$$\max \{|A|, |B|\} \leq f(k).$$

Una nozione che è stata molto utile in questa tesi è quella di *centroide*, definita a seguire.

Definizione 3.1.3. Per ogni nodo v di un albero T , le diramazioni di T rispetto a v , sono tutti i sottoalberi massimali di T non contenenti v . Per ogni $v \in T$, si definisce $\alpha(v)$ come il massimo numero di nodi tra le diramazioni rispetto a v .

Un nodo v di un albero T con n nodi, è un nodo *centroide* se $\alpha(v) \leq \frac{n}{2}$.

Il centroide di un albero non è necessariamente unico, infatti Jordan [8] ha dimostrato che, dato un albero T con n nodi:

- i T ha un singolo centroide v e $\alpha(v) < \frac{n}{2}$, oppure
- ii T ha due nodi centroidi (adiacenti) v_1 e v_2 tali che $\alpha(v_1) = \alpha(v_2) = \frac{n}{2}$, in questo caso il numero di nodi n è pari.

Esistono diversi algoritmi per la ricerca del centroide, quello utilizzato in questa tesi è un algoritmo con complessità temporale lineare nel numero di nodi che fa uso di una visita in profondità (DFS) dell'albero.

Il primo passo da effettuare è calcolare i valori $\alpha(v)$ per ogni nodo v dell'albero T . Innanzitutto per ogni nodo v di T indichiamo con $\eta(v)$ il numero di nodi presenti nel sottoalbero radicato in v di T . A questo punto si radica T in un nodo arbitrario e si procede ad una visita DFS dell'albero, memorizzando, per ogni v , il rispettivo valore $\eta(v)$, che può essere calcolato ricorsivamente nel seguente modo

$$\eta(v) = 1 + \sum_{u \text{ figlio di } v \text{ in } T} \eta(u). \quad (2)$$

Si noti che, nel caso particolare in cui v è una foglia, la formula precedente implica che $\eta(v) = 1$. Una volta conclusa la visita, si può determinare $\alpha(v)$ per ogni nodo v in T , come segue

$$\alpha(v) = \max\left\{\max_{u \text{ figlio di } v \text{ in } T} \eta(u), |T| - \eta(v)\right\}.$$

Una volta calcolato il valore di $\alpha(v)$ per ogni $v \in T$ si verifica per quali valori risulta $\alpha(v) \leq \frac{|T|}{2}$.

Per verificare che l'algoritmo ha una complessità $T(n)$ lineare sul numero di nodi. Basta notare che la visita DFS su un albero T di n nodi richiede un tempo $O(n)$ per essere completata.

A questa quantità va sommato il tempo necessario per calcolare, per ogni nodo v di T , la quantità $\eta(v)$ usando la formula (2). Ciò richiede tempo $O(1 + \delta(v))$ dove $\delta(v)$ indica il grado di v in T .

In particolare insieme quanto detto finora, ed usando l'identità $\sum_v \delta(v) = 2(n - 1)$, quello che si ottiene è:

$$T(n) = O\left(n + \sum_v (1 + \delta(v))\right) = O\left(n + n + \sum_v \delta(v)\right) = O(n + n + 2n - 2) = O(n).$$

Nell'esempio 3.1.4 si può vedere l'applicazione dell'algoritmo per la ricerca del centroide.




Figura 3.1: Albero T per la ricerca del centroide

Esempio 3.1.4. Si consideri l'albero T in figura 3.1 per la ricerca del nodo centroide.

Per ogni nodo v di T numerato da 0 a 10, viene calcolato $\alpha(v)$.

Per prima cosa calcoliamo il valore di $\eta(v)$ per ogni v di T . Avremo:

$$\begin{array}{lll}
\eta(0) = 11 & \eta(1) = 4 & \eta(2) = 6 \\
\eta(3) = 2 & \eta(4) = 1 & \eta(5) = 4 \\
\eta(6) = 1 & \eta(7) = 1 & \eta(8) = 1 \\
\eta(9) = 1 & \eta(10) = 1 &
\end{array}$$

Pertanto $\alpha(v)$ per ogni v sarà:

$$\begin{array}{lll}
\alpha(0) = \max\{6, 0\} & \alpha(1) = \max\{2, 7\} & \alpha(2) = \max\{4, 5\} \\
\alpha(3) = \max\{1, 9\} & \alpha(4) = \max\{0, 10\} & \alpha(5) = \max\{1, 7\} \\
\alpha(6) = \max\{0, 10\} & \alpha(7) = \max\{0, 10\} & \alpha(8) = \max\{0, 10\} \\
\alpha(9) = \max\{0, 10\} & \alpha(10) = \max\{0, 10\} &
\end{array}$$

Poiché $\lfloor \frac{n}{2} \rfloor = \lfloor \frac{11}{2} \rfloor = 5$, l'unico nodo per cui la disuguaglianza, $\alpha(v) \leq \frac{n}{2}$, risulta vera è il nodo 2, infatti $5 \leq 5$.

Poiché il numero di nodi è dispari certamente questo sarà l'unico centroide dell'albero T (figura 3.1). □

L'ultimo punto da considerare prima di poter enunciare e dimostrare il risultato principale di questa sezione riguarda la definizione di un algoritmo valido per decomporre un albero in due sottoalberi che chiameremo T' e T'' , in maniera $f(k)$ -bilanciata.

Sia dati in input un albero T , con $k \geq 3$ nodi. Si suppone inoltre, senza perdita di generalità, che i sottoalberi radicati nei figli della radice r di T siano ordinati in ordine non crescente. Da questo deriva che, supponendo che r abbia ℓ figli, vi saranno ℓ alberi radicati tali che: $|T_i| \geq |T_{i+1}| \quad \forall i = 1, \dots, \ell - 1$, inoltre si indica con S la seguente quantità $S = \sum_{i=1}^{\ell} |T_i|$. Sia $i = \max\{j : \sum_{h=1}^j |T_h| \leq \frac{2S}{3}\}$. L'algoritmo selezionerà T' come il sottoalbero di T indotto da r e dai nodi in T_1, \dots, T_i , e T'' di conseguenza. La decomposizione di T in T' e T'' restituita dall'algoritmo appena descritto, il cui pseudocodice è mostrato in 2, è $(\lfloor \frac{2}{3}(k-1) \rfloor + 1)$ -bilanciata, come dimostrato dal teorema a seguire.




Figura 3.2: Esempio di albero T radicato in r , con k nodi, decomposto secondo l'algoritmo 2 in due alberi T' e T'' .

Algoritmo 2: Algoritmo per il calcolo di una decomposizione $(\lfloor \frac{2}{3}(k-1) \rfloor + 1)$ -bilanciata di un albero T

```

1 input : Albero  $T$  con  $k$  nodi;
2  $r \leftarrow$  un centroide di  $T$ ;
3  $T_r \leftarrow$  albero  $T$  radicato in  $r$ ;
4  $\ell \leftarrow$  grado di  $r$  in  $T$ ;
5 Sia  $|T_i|$  l'albero radicato nell' $i$ -esimo figlio di  $r$ ;
6  $|T_i| \geq |T_{i+1}| \quad \forall i = 1, \dots, \ell - 1$ ;
7  $S \leftarrow \sum_{i=1}^{\ell} |T_i|$ ;
8 for  $i = 1, \dots, \ell$  do
9   if  $\sum_{j=1}^i |T_j| > \frac{2}{3} \cdot S$  then
10      $T' \leftarrow$  sottoalbero di  $T_r$  indotto da  $\{r\} \cup \bigcup_{j=1}^{i-1} V(T_j)$ ;
11      $T'' \leftarrow$  sottoalbero di  $T_r$  indotto da  $V(T) \setminus V(T')$ ;
12     return  $(T', T'')$ ;
13   end
14 end

```

Teorema 3.1.5. Per ogni albero T di $k \geq 3$ nodi esiste un nodo r di T tale che l'albero T_r , ottenuto radicanoado T in r , ammette una decomposizione $(\lfloor \frac{2}{3}(k-1) \rfloor + 1)$ -bilanciata. Inoltre tale decomposizione (T', T'') soddisfa $|T'| \geq 2 + \frac{(k-1)}{3}$.

Dimostrazione. Sia r sia un centroide dell'albero T e T_r l'albero T radicato in r

Inoltre, si suppone che i sottoalberi radicati nei figli di r siano ordinati in maniera non crescente rispetto al loro numero di nodi. Si applichi a T_r l'algoritmo 2 precedentemente descritto. Sia $\{T_i \mid i = 1, \dots, n\}$ l'insieme dei sottoalberi radicati negli ℓ figli di r e si consideri il primo valore di i tale che la condizione dell'if di riga 6 nell'algoritmo 2 risulti vera (si noti che tale valore di i esiste sempre dal momento che per $i = \ell$ la condizione è verificata). Sia

$$S = \sum_{j=1}^n |T_j| = (k-1)$$

e sia

$$x = \sum_{j=1}^{i-1} |T_j|$$

Distinguiamo due casi

- $i \geq 3$. In questo caso si ha che

$$x + |T_i| > \frac{2}{3} \cdot S \quad (3)$$

Inoltre per l'ordine in cui i sottoalberi T_i sono considerati

$$|T_i| \leq \frac{S}{i} \leq \frac{S}{3}. \quad (4)$$

Sottraendo la disequazione (4) alla (3) si ottiene che

$$x > \frac{2}{3} \cdot S - \frac{S}{3} = \frac{S}{3}. \quad (5)$$

- **i=2** Anche in questo caso come nel precedente vale la disequazione (3).

Inoltre, essendo $i = 2$, per l'ordine in cui vengono considerati gli alberi T_i si può dire che

$$x = |T_1| \geq |T_2| = |T_i| \quad (6)$$

Pertanto, sfruttando la disequazione (6) combinata con la (3) si ha che

$$2x > \frac{2}{3} \cdot S \Rightarrow x > \frac{S}{3} \quad (7)$$

Per entrambi i casi otteniamo che

$$x > \frac{S}{3}$$

Dal momento che x è intero otteniamo

$$x \geq \left\lfloor \frac{S}{3} \right\rfloor + 1$$

Pertanto si avrà che

$$\left\lfloor \frac{S}{3} \right\rfloor + 1 \leq x \leq \left\lfloor \frac{2}{3} \cdot S \right\rfloor \quad (8)$$

dove $x \leq \left\lfloor \frac{2}{3} \cdot S \right\rfloor$ è banalmente verificata per la scelta di i . Quindi

$$|T'| = 1 + x \leq 1 + \left\lfloor \frac{2}{3} \cdot S \right\rfloor = 1 + \left\lfloor \frac{2}{3} \cdot (k-1) \right\rfloor \quad (9)$$

e

$$|T''| = 1 + S - x = 1 + S - 1 - \left\lfloor \frac{S}{3} \right\rfloor = \left\lceil \frac{2}{3} \cdot S \right\rceil = \left\lceil \frac{2}{3} \cdot (k-1) \right\rceil \quad (10)$$

Poichè

$$1 + \left\lfloor \frac{2}{3} \cdot (k-1) \right\rfloor \geq \left\lceil \frac{2}{3} \cdot (k-1) \right\rceil$$

Possiamo concludere che

$$\max\{|T'|, |T''|\} \leq 1 + \left\lfloor \frac{2}{3} \cdot (k-1) \right\rfloor$$

Infine da (8) segue che

$$|T'| = 1 + x \geq 1 + \left(1 + \left\lfloor \frac{S}{3} \right\rfloor\right) = 2 + \left\lfloor \frac{(k-1)}{3} \right\rfloor$$

□

3.2 Algoritmo

In questa sezione si vede come è stato utilizzato il risultato della sezione 3.1 per ottimizzare e migliorare l'algoritmo 1 descritto nel capitolo 2 (paragrafo 2.1).

Quello che si faceva in precedenza era, dato un albero T_C , con T un albero radicato di k nodi i cui colori giacciono in C , si procedeva al conteggio delle occorrenze di T_C nel seguente modo

$$c(T_C, v) = \frac{1}{\beta_T} \sum_{(u,v) \in E} \sum_{\substack{C', C'' \subset C: |C'| = |T'| \\ C' \cup C'' = C \\ C' \cap C'' = \emptyset}} c(T'_{C'}, v) \cdot c(T''_{C''}, u)$$

dove T' e T'' sono due alberi ottenuti tramite un'opportuna decomposizione di T tali che $|T'|, |T''| \in \{1, \dots, k-1\}$, T'' (e $|T''| = k - |T'|$), mentre $T'_{C'} = (T', C')$ e $T''_{C''} = (T'', C'')$ sono due treelet colorati, radicati rispettivamente in v ed u .

In questa nuova versione, invece, T_C viene suddiviso in due alberi T' e T'' tali da rispettare il principio delle decomposizioni bilanciate e più nello specifico il teorema 3.1.5.

Innanzitutto si determina se l'albero T_C è radicato in uno dei centroidi, nel caso in cui ciò non fosse vero, l'albero T_C non viene conteggiato. Successivamente viene suddiviso T_C in due alberi $T'_{C'}$ e $T''_{C''}$ tali che: entrambi gli alberi risultino radicati nella stessa radice r di T , $\max\{|T'|, |T''|\} \leq 1 + \lfloor \frac{2}{3} \cdot (k-1) \rfloor$ e $|T'| \geq 2 + \lfloor \frac{k-1}{3} \rfloor$. Inoltre i due insiemi C' e C'' dovranno essere tali che $C' \cup C'' = C$ e $C' \cap C'' = \{c_r\}$, dove c_r il colore del nodo radice.

Come nel caso precedente, l'algoritmo che si utilizza per il conteggio delle occorrenze dei k -treelet colorati in G utilizza la tecnica della programmazione dinamica, quindi si procede dai sottoproblemi più piccoli arrivando a quello più grande.

Anche qui per ogni nodo v si inizializza $c(T_{C_0}, v) = 1$, dove $T_{C_0} = (T, C_0)$, T è il treelet di 1 nodo e $C_0 = \{c_v\}$. Questa volta, però, per calcolare le occorrenze dei k -treelet radicati in ogni $v \in V$ di G non sarà necessario aver calcolato il numero di occorrenze degli h -treelet con $h = 1, \dots, k-1$, ma sarà necessario calcolarli solo fino a $h \leq \lfloor \frac{2}{3}(k-1) \rfloor + 1$. Tale conteggio verrà eseguito sulla base dell'algoritmo 1 di sezione 2.1.

Per calcolare per ogni nodo $v \in V$ di G il numero $c(T_C, v)$ di occorrenze dei k -treelet (non indotti) radicati in v isomorfi a T i cui colori giacciono nell'insieme C si sfrutta la seguente relazione:

$$c(T_C, v) = \frac{1}{\gamma_T} \sum_{\substack{C', C'' \subseteq C: |C'|=|T'| \\ C' \cup C'' = C \\ C' \cap C'' = \{c_r\}}} c(T'_{C'}, v) \cdot c(T''_{C''}, v)$$

con γ_T la nuova costante di normalizzazione che è uguale a $\binom{p}{q}$, dove p è il numero di sottoalberi di T isomorfi al sottoalbero radicato nell'ultimo figlio della radice di T' e q il numero di sottoalberi radicati a partire dal primo figlio della radice di T'' isomorfi al sottoalbero radicato nell'ultimo figlio della radice di T' . Di seguito viene riportato lo pseudocodice dell'algoritmo precedentemente descritto.

Algoritmo 3: Algoritmo di costruzione per i k -treelet in T usando le decomposizioni $(\lfloor \frac{2}{3}(k-1) \rfloor + 1)$ -bilanciate

```

1 input : Grafo  $G = (V, E)$ , dimensione del treelet di interesse  $k \geq 3$ ;
2 for  $h = 1$  to  $\lfloor \frac{2}{3}(k-1) \rfloor + 1$  do
3   | Si calcolano le occorrenze secondo quanto riportato nell'Algoritmo 1;
4 end
5 for  $v \in V$  do
6   foreach  $T : |T| = k$  do
7     | Sia  $c$  un centroide di  $T$ ;
8     if  $c \neq v$  then
9       | continue;
10    end
11    Suddivido  $T$  in due alberi  $T'$  e  $T''$  come descritto in precedenza;
12
13    
$$c(T_C, v) = \frac{1}{\gamma_T} \sum_{\substack{C', C'' \subseteq C: |C'| = |T'| \\ C' \cup C'' = C \\ C' \cap C'' = \{c_r\}}} c(T'_{C'}, v) \cdot c(T''_{C''}, v)$$

14  end
15 end

```

Come nell'algoritmo 1 il numero di occorrenze di T è calcolato con un approccio basato sulla scomposizione dell'albero in due sottoalberi, però, anche in questo caso nella tesi l'algoritmo 3 è stato implementato nel verso opposto.

Ossia presi due alberi T' e T'' , radicati entrambi nello stesso nodo r , si verifica unendo i due alberi, ossia appendendo alla radice di T' tutti i sottoalberi radicati nella radice di T'' , si generi un albero T radicato in r valido, i cui conteggi sono ottenuti a partire dai conteggi di T' e T'' . Perciò per calcolare le occorrenze dei k -treelet in G , $\forall v \in V$ di G si prendono tutte le possibili coppie di alberi colorati $(T'_{C'}, T''_{C''})$ radicate in v tali che: $2 + \lfloor \frac{k-1}{3} \rfloor \leq |T'| \leq \lfloor \frac{2}{3}(k-1) \rfloor + 1$ e $|T''| = k - |T'|$. Per poter unire T' e T'' è necessario che valgano proprietà siano verificate:

- bisogna verificare che la coppia (T', T'') sia una decomposizione bilanciata per T . Pertanto dovrà risultare che $|T'| - 1 \leq \lfloor \frac{2}{3}(k-1) \rfloor$ e che aggiungendo a tale

quantità la cardinalità del sottoalbero radicato nel primo figlio di T'' , denotata con t'' , si abbia che $|T'| + t'' - 1 \geq \lfloor \frac{2}{3}(k-1) \rfloor$.

- Anche in questo caso bisognerà garantire l'ordinamento sui sottoalberi radicati nei figli dell'albero generato dall'unione di T' e T'' . Pertanto non sarà possibile unire T' e T'' se la dimensione del sottoalbero radicato nell'ultimo figlio della radice di T' è minore del sottoalbero radicato nel primo figlio della radice di T'' .
- Bisogna garantire che sia rispettato i vincoli sui colori: $C' \cup C'' = C$ e $C' \cap C'' = \{c_r\}$, ossia i due insiemi C' e C'' condividono esclusivamente in colore della radice r .
- bisogna verificare che il nodo r sia il centroide dell'albero T risultante dall'unione di T' e T'' .

Queste condizioni sono necessarie affinché l'unione tra gli alberi $T'_{C'}$ e $T''_{C''}$ produca un albero valido T_C .

Come si nota, anche in questo caso, i conteggi inizialmente vengono fatti su ogni $v \in V$, ma poichè in questa tesi interessano le occorrenze dei diversi k -treelet in G sarà necessario aggregare gli alberi radicati su ogni v di G , unendoli a seconda della propria struttura e sommando le rispettive occorrenze.

Nel caso in cui si abbiano due centroidi, la scelta su quale radicare l'albero segue delle regole precise. Nel caso in cui gli alberi ottenuti radicando T in ognuno di essi abbiano strutture differenti, viene scelto quello che tra i due ha una struttura più piccola. Altrimenti se gli alberi ottenuti sono identici vengono mantenuti entrambi, ma questo implica che tali alberi vengano conteggiati un numero di volte doppio rispetto al conteggio reale. Perciò in fase di normalizzazione i conteggi di tutti gli alberi per cui questa condizione risulta vera saranno ulteriormente divisi per due.

Come per la versione non bilanciata anche questi conteggi si riferiscono al numero di occorrenza di un k -treelet T in G ben colorato con k colori distinti. Perciò anche in questo caso per ottenere uno stimatore unbiased del numero di occorrenze di T bisognerà moltiplicare il numero di occorrenze ben colorate per $\frac{k^k}{k!}$.

3.3 Dettagli implementativi. Modifica e aggiunte alle rappresentazioni

Anche in questa nuova versione gli oggetti principali manipolati restano i treelet colorati e le occorrenze associate.

Ogni treelet colorato $T_C = (T, C)$ continua ad avere una rappresentazione unica, memorizzata usando interi a 64 bit. I bit hanno lo stesso ordinamento della precedente versione. Quello che cambia, però, è la suddivisione dei bit:

- i bit da 0-3 contengono un valore numerico che è pari ad 1 se l'albero ha un solo centroide o due centroidi tali che, gli alberi ottenuti radicando T in ognuno di essi risultino diversi. Mentre è pari a 2 se l'albero ha due centroidi tali che, gli alberi ottenuti radicando T in ognuno di essi risultino uguali.
- i bit da 4-7 contengono il numero μ di sottoalberi in T'' radicati a partire dal primo figlio della radice isomorfi al sottoalbero radicato nell'ultimo figlio della radice di T' .
- i bit da 8-11 contengono il valore q necessario nel calcolo binomiale $\binom{p}{q}$ usato in fase di normalizzazione. La somma di q con μ restituisce p .
- i bit da 12-63 restano invariati alla versione precedente.

La struttura dell'albero è codificata esattamente come la versione precedente, in particolare i sottoalberi radicati nei figli della radice dell'albero, appaiono in ordine non crescente rispetto alle relative rappresentazioni, definendo implicitamente un ordinamento totale sui treelet (colorati).

Alle precedenti operazioni sugli alberi se ne aggiungono delle nuove che sono:

- **balance_merge(T', T'')** : fa l'unione di due alberi T' e T'' in maniera bilanciata. All'interno del metodo viene garantito che tutte le condizioni necessarie affinché l'unione avvenga, descritte in fondo al paragrafo precedente, siano verificate.

- **normalization_factor_balanced**(T) : restituisce il fattore di normalizzazione γ_T dell'unione bilanciata.

Un'altra differenza rispetto la versione precedente riguarda la costruzione della tabelle. Infatti, seguendo quanto descritto in algoritmo 3, verranno costruite tutte le entrate da 1 a $\lfloor \frac{2}{3}(k-1) \rfloor + 1$ come veniva fatto nella versione precedente. Mentre non verranno costruite le h tabelle tali che: $\lfloor \frac{2}{3}(k-1) \rfloor + 1 < h < k$, ma si procederà direttamente alla costruzione della tabella contenente i k -treelet.

Anche in questa versione i treelet colorati raggiunti $\forall v \in V$ verranno aggregati e i loro conteggi sommati ed anche in questa versione i conteggi di nodi differenti (per ogni valore di h fissato) vengono calcolati in parallelo da più thread.

CAPITOLO 4

ANALISI SPERIMENTALE

Nel presente lavoro di tesi è stata descritto un algoritmo per il conteggio di k -treelet basato sulla tecnica del Color Coding (capitolo 2). È stato mostrato come tale algoritmo può essere sfruttato per la ricerca e il conteggio approssimato di tutti i k -treelet colorati presenti in un grafo $G = (V, E)$. Si è visto come, in questa tesi, l'algoritmo sia stato sviluppato con un approccio basato sulle unioni tra alberi piuttosto che sulle scomposizioni e sono state discusse le scelte implementative sviluppate per rappresentare i treelet colorati e i conteggi associati.

Sucessivamente si è provveduto a introdurre un'ottimizzazione a tale algoritmo. Per fare ciò è stato necessario introdurre alcune nozioni fondamentali come ad esempio la nozione di centroide e di decomposizioni bilanciate, l'algoritmo risultante è stato descritto nel capitolo 3. Anche per questo nuovo algoritmo, come per il precedente, il conteggio dei k -treelet basandosi sull'unione piuttosto che sulle decomposizioni.

Infine sono stati messi a confronto i risultati ottenuti con l'esecuzione di entrambe le implementazioni, discutendo l'accuratezza dei risultati ed il risparmio in termini di tempo che si è ottenuto usando l'algoritmo ottimizzato.

Come detto inizialmente, il lavoro di tesi si è concentrato solo sul conteggio k -treelet (non indotti) di un grafo G . Cionondimeno, in [6, 7] è mostrato come sia possibile campionare (e contare) le occorrenze dei k -graphlet di interesse nel grafo in input G avendo a disposizione un algoritmo in grado di campionare i k -treelet di G . A tale scopo le tecniche descritte in [6, 7] possono essere facilmente adattate per

restituire un k -treelet di G ben colorato uniformemente a caso a partire dai conteggi $c(T_C, v)$ calcolati dall'Algoritmo 3 permettendo così di applicare le ottimizzazioni descritte nella tesi anche al problema, più generale, della stima delle occorrenze dei motif in un grafo.

- [1] Mansurul A Bhuiyan, Mahmudur Rahman, Mahmuda Rahman, and Mohammad Al Hasan. Guise: Uniform sampling of graphlets for large graph analysis. In *2012 IEEE 12th International Conference on Data Mining*, pages 91–100. IEEE, 2012.
- [2] Zhao Zhao, Maleq Khan, VS Anil Kumar, and Madhav V Marathe. Subgraph enumeration in large social contact networks using parallel color coding and streaming. In *2010 39th International Conference on Parallel Processing*, pages 594–603. IEEE, 2010.
- [3] Paolo Boldi, Marco Rosa, Massimo Santini, and Sebastiano Vigna. Layered label propagation: A multiresolution coordinate-free ordering for compressing social networks. In *Proceedings of the 20th international conference on World wide web*, pages 587–596, 2011.
- [4] Noga Alon, Phuong Dao, Iman Hajirasouliha, Fereydoun Hormozdiari, and S Cenk Sahinalp. Biomolecular network motif counting and discovery by color coding. *Bioinformatics*, 24(13):i241–i249, 2008.
- [5] Noga Alon, Raphael Yuster, and Uri Zwick. Color-coding. *Journal of the ACM (JACM)*, 42(4):844–856, 1995.
- [6] Marco Bressan, Flavio Chierichetti, Ravi Kumar, Stefano Leucci, and Alessandro Panconesi. Motif counting beyond five nodes. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 12(4):1–25, 2018.

- [7] Marco Bressan, Stefano Leucci, and Alessandro Panconesi. Motivo: fast motif counting via succinct color coding and adaptive sampling. *Proceedings of the VLDB Endowment*, 12(11):1651–1663, 2019.
- [8] Camille Jordan. Sur les assemblages de lignes. *J. Reine Angew. Math*, 70(185):81, 1869.

RINGRAZIAMENTI

Indipendente dall'ambito tutti abbiamo delle aspirazioni nella vita e, per arrivarci, dobbiamo fissare degli obiettivi da raggiungere cercando poi di superarli.

Gli obiettivi ci aiutano a capire dove vogliamo andare e che strada prendere quando ci tocca fare delle scelte. Per questo è molto importante averli sempre davanti a noi senza distogliere lo sguardo.

Io oggi ho raggiunto uno dei miei obiettivi e superato uno dei traguardi importanti della vita.

Ma per farlo non posso non ringraziare tutti quelli che hanno camminato insieme a me in questo percorso.

Voglio, innanzitutto, ringraziare il mio relatore il Dr. Stefano Leucci. Nonostante la pandemia, con le tante chiamate su teams, mi ha permesso di scoprire un mondo nuovo ed affascinante, continuamente in evoluzione. Grazie.

Voglio ringraziare *Alessia*, *Claudia* e *Giada* che mi hanno supportato anche in questo viaggio. Ammetto di non essere una persona facile, cambio idea mille volte, ho sempre qualche nuova cosa assurda che mi passa per la testa, ma voi non mi avete mai giudicato, ci siete sempre state a supportarmi, sopportarmi o cazziarmi se occorreva. Grazie

Ringrazio *Roberta* ed *Alessandro*, che nonostante i mille impegni reciproci ci so-

no sempre stati, per una chiacchiera, una risata o solo per i dieci minuti di un caffè.
Grazie

Ringrazio *Annaluna* e *Angela*. La prima è il mio grillo parlante, quando sto per sbagliare immagino di sentire lei che mi dice “non farlo” oppure “ci può stare” e mi comporta di conseguenza. La seconda è la follia pura, l’allegria e le mille chiacchiere fatte insieme. Grazie

Ringrazio *Alessandro*, il mio amore. Grazie a te ho capito quanto valgo e quello che posso dare. Sei la mia ancora nei momenti bui e il mio conforto nei giorni grigi. Non possiamo lavorare insieme questo è sicuro, ma possiamo continuare a supportarci reciprocamente lungo il percorso che ci si sta formando davanti. Insieme a te ringrazio anche la tua splendida famiglia, che mi ha accolto a braccia aperte dal primo giorno. Grazie

Laura e *Miriana*, solo una cosa vi accomuna, la mia iniziale antipatia nei vostri confronti, ma si sa le apparenze ingannano. Grazie a voi ho imparato, sicuramente, che non bisogna fermarsi alle apparenze e non giudicare mai il libro dalla copertina, perchè dietro c’è spesso molto molto di più. Grazie

Grazie a te *Erika*, la mia compagna di viaggio dal primo giorno, la mia spalla destra e altre volte sinistra. Non pensavo di trovare una grande amicizia così in questo viaggio, in realtà continuavo ad essere convinta di non averne neanche bisogno, invece mi sbagliavo. Adesso continuiamo il nostro percorso insieme e arriviamo più lontano che possiamo. Grazie.

Ringrazio tutti gli amici “vecchi” e “nuovi”, che con un sorriso o una chiacchiera, hanno reso meno noiose e ripetitive le mie giornate. Grazie

Un ringraziamento speciale va alla mia famiglia grande e pazzarella, ai miei fratelli, *Giorgia*, *Federico* e *Salvatore*, ai loro fidanzati, *Crystal* e *Lorenzo*, ma soprattutto

a loro due *Mamma e Papà*, le mie rocce. È solo grazie a voi, ai vostri sacrifici ed ai vostri insegnamenti che non mi è mai mancato niente nella vita. È solo grazie a voi e al vostro supporto quando vi ho detto che volevo riprendere a studiare che posso dire di essere qui oggi. Spesso vi dò per scontati, ma poichè nulla è scontato in questa vita e gli ultimi mesi ne sono stati la dimostrazione, sappiate che il mio ringraziamento più grande va a voi. Ancora mille volte grazie.

L'ultimo ringraziamento, ma non per importanza va a me. Devo ringraziarmi per aver deciso di stravolgermi la vita, fare un salto nel vuoto e darmi una possibilità. Una possibilità di ottenere il futuro che desidero, la possibilità di fare quello che voglio e di diventare ciò che voglio essere. Alla Giulia del futuro dico non perdere l'ambizione che hai, continua a guardare il mondo che ti circonda con curiosità e non smettere di sognare e di volere sempre di più. Grazie a me.

Dimenticavo di ringraziare i miei Nonni, non sono riuscita a portarvi in questo giorno con me fisicamente, ma vi porto tutti nel cuore. Mi mancate sempre, ma so che ci siete.

Grazie.